

Machine Learning I

Proyecto Final

Estudiantes: Sebastián Gómez (0000261948), Leonardo Montoya
(0000286207) y Andrea Urdaneta (0000257784)

Ingeniería Informática e Ingeniería Industrial

Universidad de la

Sabana

Maestría en

Analítica Aplicada

Profesor: Hugo

Franco, Ph.D.

20 de octubre de

2025

1. Proyecto Final Machine Learning I

1.1 Descripción del problema

El presente análisis tiene como propósito estudiar las relaciones entre el desempeño académico de los estudiantes en las pruebas SABER 11 (educación media) y SABER PRO (educación superior), junto con factores de carácter socioeconómico, educativo y tecnológico. El objetivo principal es comprender qué variables explican en mayor medida el rendimiento global de los estudiantes en la prueba SABER 11, representado en la suma de los puntajes en cada una de las cinco áreas, y a su vez, qué patrones permiten clasificar a los estudiantes que presentaron el SABER PRO dentro de sus respectivos niveles de desempeño (QUARTILE).

Este análisis es particularmente relevante porque permite identificar patrones de desigualdad educativa, factores predictivos del rendimiento académico, y vínculos entre el contexto familiar y el desempeño posterior en la educación superior. Los resultados obtenidos proporcionan evidencia cuantitativa sobre los determinantes del éxito académico, facilitando la identificación de estudiantes en riesgo y el diseño de intervenciones educativas oportunas. La investigación emplea un enfoque metodológico basado en machine learning, combinando técnicas de clasificación y regresión para modelar las relaciones complejas entre las variables. Los hallazgos de esta fase diagnóstica servirán como base fundamental para los modelos predictivos desarrollados en la siguiente etapa del proyecto, contribuyendo al mejoramiento de la calidad educativa y la reducción de brechas de equidad en el sistema de educación superior colombiano.

1.2. Método de solución

Se llevó a cabo un proceso metodológico que combinó limpieza de datos, transformación de variables y análisis exploratorio-descriptivo, con el fin de depurar la información y detectar relaciones significativas entre los indicadores académicos y socioeconómicos.

En primer lugar, se eliminaron duplicados y valores nulos, se homogenizaron los textos categóricos y se descartaron variables no informativas (SYSBEND, TV, DVD). Posteriormente, se normalizaron variables ordinales como REVENUE, STRATUM y PEOPLE_HOUSE, garantizando coherencia numérica entre categorías. También se eliminaron los puntajes específicos de las áreas del SABER-PRO (QR_PRO, CR_PRO, CC_PRO, ENG_PRO, WC_PRO, FEP_PRO) y los indicadores relativos (PERCENTILE) para evitar redundancias, conservando únicamente las variables relevantes para los modelos de regresión (total_score construida a partir de la suma de los valores en cada una de las cinco áreas del SABER 11) y clasificación (QUARTILE).

El análisis exploratorio se diseñó para responder las siguientes preguntas clave:

1. ¿Cuál es la distribución general de los puntajes globales (G_SC)?
2. ¿Existe relación entre el nivel de ingreso (REVENUE) y los puntajes obtenidos en el SABER-PRO?
3. ¿El acceso a computador influye en el desempeño académico?
4. ¿La educación del padre o la madre incide en los resultados de los estudiantes?
5. ¿Qué universidades presentan los promedios más altos en el SABER-PRO?
6. ¿Existen diferencias significativas en el desempeño por género?
7. ¿Qué correlaciones se observan entre las variables numéricas del dataset?

Estas preguntas guiaron la exploración visual y estadística del conjunto de datos, permitiendo interpretar tendencias, contrastar hipótesis y establecer las relaciones fundamentales que explican el rendimiento académico de los estudiantes.

Para el desarrollo de los modelos predictivos, se implementó un pipeline de machine learning estructurado en Python mediante Prefect, utilizando scikit-learn, imbalanced-learn y entre otras herramientas. El proceso técnico incluyó:

- Preprocesamiento automatizado mediante ColumnTransformer, aplicando imputación por mediana para variables numéricas y escalado estándar, junto con codificación one-hot para variables categóricas.
- División estratificada de los datos (80% entrenamiento, 20% prueba) para garantizar representatividad de las clases en los problemas de clasificación.
- Balanceo de clases con la técnica SMOTE en el pipeline de clasificación para abordar el desbalance natural en los cuartiles académicos.
- Entrenamiento comparativo de múltiples algoritmos: K-Vecinos más Cercanos, Máquinas de Vectores de Soporte, Regresión Logística y Random Forest optimizados mediante RandomizedSearchCV con validación cruzada.
- Evaluación comprehensiva utilizando métricas robustas como exactitud balanceada, matrices de confusión, RMSE y reportes de clasificación para asegurar la calidad predictiva de los modelos.

El pipeline técnico permitió desarrollar simultáneamente modelos de clasificación para predecir el cuartil académico de los estudiantes que presentaron el SABER PRO y modelos de regresión para predecir el puntaje total de los estudiantes que presentaron el SABER 11, implementando mejores prácticas de reproducibilidad y escalabilidad en el proceso de modelado.

1.3. Resultados





Figura 1 – Dispersión del puntaje global (G_SC)

El gráfico muestra una concentración de puntajes entre 150 y 180, con valores atípicos superiores a 220. Esto sugiere una distribución moderadamente sesgada hacia la derecha, indicando que la mayoría de los estudiantes que presentaron el SABER PRO se ubican en niveles medios de desempeño.



Figura

Figura 2 – Promedio de puntajes SABER-PRO según nivel de ingresos (REVENUE)

Se observa una tendencia claramente ascendente: a medida que aumenta el nivel de ingreso familiar, también lo hacen los puntajes promedio en todas las áreas y en el puntaje global (G_SC). Esto confirma que los factores económicos guardan una relación positiva con el desempeño académico.




Figura 3 – Promedio de puntajes SABER-PRO según acceso a computador

Los estudiantes con acceso a computador presentan puntajes consistentemente más altos, con una diferencia promedio de 8 a 10 puntos en comparación con quienes no disponen de uno. Esto refuerza la hipótesis de que el acceso tecnológico contribuye al aprendizaje y desempeño en las pruebas.




Figura 4 – G_SC promedio según educación del padre




Figura 5 – G_SC promedio según educación de la madre

Los resultados muestran una relación positiva entre el nivel educativo de los padres y el rendimiento académico. Los estudiantes cuyos padres poseen educación profesional o de posgrado alcanzan puntajes globales más altos, mientras que los niveles de educación básica o incompleta se asocian con rendimientos más bajos.




Figura 6 – Top 15 universidades por puntaje promedio (G_SC)

Las universidades con mejor rendimiento son la Universidad de los Andes, la EIA Medellín, la Universidad Nacional, EAFIT y la Universidad del Norte, todas con promedios globales superiores a 180 puntos. Esto refleja diferencias institucionales significativas en calidad académica y preparación estudiantil.




Figura 7 – Distribución porcentual de cuartiles (QUARTILE) por género

La distribución por cuartiles evidencia que tanto hombres como mujeres se concentran mayoritariamente en los niveles 3 y 4, sin diferencias marcadas. Sin embargo, una leve mayor proporción de hombres alcanza el cuartil superior, lo que podría reflejar diferencias de desempeño en áreas específicas del examen.




Figura 8 – Matriz de correlación de variables numéricas

El análisis de correlación revela asociaciones fuertes entre las competencias del SABER-PRO y el puntaje global (G_SC), validando su consistencia interna. Las variables socioeconómicas (STRATUM, REVENUE, COMPUTER, INTERNET) muestran correlaciones positivas moderadas, mientras que los puntajes de SABER-11 presentan correlaciones significativas con los resultados universitarios, evidenciando continuidad académica. Además, claramente se ve correlación entre los puntajes de cada área y el global, y los percentiles, esto dada la naturaleza del puntaje global que depende de estas variables. Para los modelos no se utilizaron evidentemente.




Figura 9 – Histograma de la variable objetivo construida

Por último, se realizó un histograma para visualizar el comportamiento de la variable objetivo construido `total_score` que representa la suma de los valores de las cinco áreas de la prueba SABER 11, de modo que correspondería al puntaje final de cada estudiante. Mediante este gráfico se puede observar que se presenta una leve asimetría positiva y que la mayoría de los puntajes se distribuyen entre los valores 250 y 400.

Por otro lado, pasando a los resultados obtenidos de los modelos predictivos se encontraron los siguientes resultados:

```
== Entrenando SVM ==
Test Accuracy: 0.960 | Balanced Accuracy: 0.957

Matriz de confusión:
[[ 196   9   0   0]
 [   7 366  12   0]
 [   0  15 602  12]
 [   0   0  45 1219]]

Reporte de clasificación:
      precision    recall  f1-score   support

     0       0.966       0.956       0.961         205
     1       0.938       0.951       0.945         385
     2       0.914       0.957       0.935         629
     3       0.990       0.964       0.977        1264

 accuracy          0.960         2483
 macro avg       0.952       0.957       0.954         2483
 weighted avg    0.961       0.960       0.960         2483
```

Figura 10 – Métricas para el modelo SVM

El modelo SVM demostró un excelente desempeño en la clasificación de cuartiles académicos. La matriz de confusión revela una alta capacidad predictiva, especialmente para los cuartiles más altos (clase 3 relativa al cuartil 4), donde logra 1219 aciertos de 1264 casos. Se observa cierta confusión entre las clases 1 y 2, con 12 casos mal clasificados, lo que sugiere que estos cuartiles presentan características similares. La precisión y recall equilibrados en todas las clases indican un modelo robusto y generalizable.




Figura 11 – Métricas para el modelo KNN

KNN presenta el desempeño más bajo entre los clasificadores, evidenciando limitaciones para capturar la complejidad de los patrones académicos. La matriz de confusión muestra problemas significativos en la clase 2, donde 106 casos se confunden con la clase 1, y en la clase 3, donde 310 casos se clasifican erróneamente como clase 2. Esto indica que el modelo basado en proximidad tiene dificultades para distinguir entre cuartiles adyacentes, posiblemente debido a la superposición en las características de los estudiantes. Además, es el modelo que más tiempo toma en ser entrenado por lo que su eficiencia computacional también es puesta en tela de juicio.

```

== Entrenando Logistic ==
Test Accuracy: 0.965 | Balanced Accuracy: 0.957

Matriz de confusión:
[[ 192  13   0   0]
 [   8 368   9   0]
 [   0  15 607   7]
 [   0   0  35 1229]]

Reporte de clasificación:
      precision    recall  f1-score   support

     0       0.960     0.937     0.948        205
     1       0.929     0.956     0.942        385
     2       0.932     0.965     0.948        629
     3       0.994     0.972     0.983       1264

 accuracy          0.965          2483
  macro avg       0.954          2483
 weighted avg     0.966          2483

```

Figura 12 – Métricas para el modelo Logistic

La Regresión Logística obtuvo el mejor desempeño global, destacándose por su balance entre precisión y recall sobre todas las clases. La matriz de confusión muestra patrones de error mínimos, con solo 13 casos mal clasificados en la clase 0 y 35 en la clase 3. La consistencia en las métricas por clase (todas por encima del 93%) confirma que este modelo generaliza excelentemente bien para todos los cuartiles, haciendo de él el clasificador más confiable del conjunto.

```

== Entrenando RandomForest ==
Test Accuracy: 0.959 | Balanced Accuracy: 0.934

Matriz de confusión:
[[ 184  16   4   1]
 [   2 336  45   2]
 [   0   4 621   4]
 [   0   0  25 1239]]

Reporte de clasificación:
      precision    recall  f1-score   support

     0       0.989     0.898     0.941        205
     1       0.944     0.873     0.907        385
     2       0.894     0.987     0.938        629
     3       0.994     0.980     0.987       1264

 accuracy          0.959          2483
  macro avg       0.955          2483
 weighted avg     0.961          2483

```

Figura 13 – Métricas para el modelo RandomForest

Random Forest presenta un buen desempeño general, aunque con una exactitud balanceada ligeramente inferior a SVM y Regresión Logística. La matriz de confusión revela una particular dificultad con la clase 1, donde 45 casos se confunden con la clase 2. Sin embargo, destaca en la identificación de la clase 2, con solo 4 errores de clasificación. El modelo muestra una alta precisión en los extremos (clases 0 y 3), pero cierta inestabilidad en las clases intermedias.

```
Entrenando modelos de regresión...  
== Entrenando (reg) KNN ==  
KNN RMSE: 12.917  
== Entrenando (reg) SVR ==  
SVR RMSE: 4.645
```

Figura 14 – Resumen modelos de regresión

En cuanto a los dos modelos de regresión implementado se evaluaron las métricas de desempeño utilizando el Error Cuadrático Medio (RMSE) como indicador principal. Los resultados muestran diferencias significativas en la capacidad de predicción entre los modelos evaluados. El modelo KNN presentó un RMSE de 12.917, lo que indica una mayor dispersión de los errores respecto a los valores reales. En contraste, el modelo SVR obtuvo un RMSE considerablemente menor, de 4.645, reflejando una mayor precisión en sus predicciones. Considerando estos resultados, el modelo SVR resulta más atractivo al ofrecer un mejor ajuste a los datos y, por tanto, es el candidato más adecuado para el problema de regresión analizado.

Retomando, los resultados de los modelos de clasificación, la Regresión Logística se destacó como el modelo más eficiente, mostrando un desempeño consistente y equilibrado entre las clases, incluso ante posibles desbalances en los datos. Además, el valor óptimo del hiperparámetro $C = 1$ evidenció un adecuado nivel de regularización, permitiendo al modelo generalizar correctamente sin caer en sobreajuste.

En pocas palabras, la comparativa general revela que los modelos lineales y basados en kernels superaron significativamente a los métodos basados en instancias y ensembles en el problema de clasificación. Esto sugiere que las relaciones entre las variables académicas y los cuartiles son fundamentalmente lineales o separables linealmente en espacios de alta dimensión. Mientras que la tarea de regresión resultó más desafiante que la clasificación por cuartiles, la alta predictibilidad de los rangos académicos sugiere que existen patrones bien definidos en las trayectorias educativas que pueden ser identificados tempranamente para intervenciones oportunas.

1.4. Discusión y Conclusiones

Los hallazgos de este estudio revelan patrones consistentes sobre los determinantes del rendimiento académico en educación superior con implicaciones prácticas directas para el sistema educativo colombiano. El análisis confirma que, si bien los factores socioeconómicos, tecnológicos y educativos familiares muestran una influencia medible en el desempeño universitario, los antecedentes académicos

previos, particularmente los puntajes SABER 11, emergen como el predictor más sólido del éxito en SABER PRO. Esta primacía de lo académico sobre lo contextual sugiere que las competencias desarrolladas durante la educación media constituyen un capital cognitivo determinante que, en muchos casos, logra compensar las desventajas socioeconómicas iniciales, siendo este un hallazgo esperanzador que destaca el poder igualador de una educación media de calidad.

Entre los modelos de clasificación evaluados, la Regresión Logística se estableció como el algoritmo de mejor desempeño global, alcanzando una exactitud del 96.5% en la clasificación por cuartiles académicos. Su superioridad no es solo técnica, sino que tiene implicaciones prácticas profundas: al ser un modelo interpretable, permite a instituciones educativas y formuladores de políticas identificar exactamente qué variables influyen más en el éxito académico y diseñar intervenciones basadas en evidencia concreta, no en suposiciones. Las aplicaciones en el mundo real de este hallazgo son inmediatas y transformadoras. Las instituciones de educación superior podrían implementar este modelo al momento de la admisión para identificar estudiantes en riesgo desde su primer semestre y asignar recursos de acompañamiento académico de manera proactiva. Los resultados sugieren que, con una precisión del 96.5%, se podría predecir qué estudiantes necesitarán programas de nivelación desde incluso antes de que comiencen sus carreras, optimizando significativamente los recursos de tutoría y apoyo académico.

A nivel de política pública, el modelo ofrece una herramienta poderosa para evaluar la efectividad real de los programas de acceso a la educación superior. Al poder predecir con alta certeza el desempeño esperado de diferentes grupos poblacionales, los gobiernos podrían diseñar estrategias de equidad más efectivas y medir su impacto en tiempo real. Las secretarías de educación de todo el país podrían usar estos resultados para fortalecer específicamente aquellas competencias en educación media que más impactan el futuro universitario.

Por otro lado, los modelos de regresión aplicados sobre los datos del SABER 11 mostraron una capacidad adecuada para aproximar los puntajes numéricos de los estudiantes a pesar de que los modelos de clasificación entrenados con información del SABER PRO evidenciaron un desempeño más robusto para categorizar niveles o cuartiles de desempeño. Esta diferencia no representa una contradicción, sino que refleja la naturaleza distinta de cada subconjunto de datos y de los objetivos de predicción. En conjunto, ambos enfoques ofrecen una visión complementaria del rendimiento académico: la regresión permite estimar tendencias cuantitativas tempranas, mientras que la clasificación facilita identificar patrones de logro en etapas avanzadas de formación.

En conclusión, este estudio trasciende el ámbito técnico para posicionarse como una herramienta concreta para la transformación educativa. La implementación del modelo de Regresión Logística identificado como óptimo podría marcar un punto de inflexión en cómo las instituciones educativas colombianas abordan la retención estudiantil, el apoyo académico temprano y la equidad educativa, demostrando que la analítica de datos bien aplicada puede convertirse en un poderoso motor de movilidad social y calidad educativa.

Referencias

Brownlee, J. (2020). *Data Preparation for Machine Learning: Data Cleaning, Feature Selection, and Data Transforms in Python*. Machine Learning Mastery.

Burkov, A. (2019). *The Hundred-Page Machine Learning Book*. Andriy Burkov.

De La Hoz, E. (2020). *Data of Academic Performance evolution for Engineering Students* [Data set]. Mendeley Data. <https://doi.org/10.17632/83tcx8psxv.1>

Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

Hastie, T., Tibshirani, R., & Friedman, J. (2017). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.

Raschka, S., & Mirjalili, V. (2022). *Python Machine Learning* (4th ed.). Packt Publishing.